📙

텍스트데이터분석_뷰티풀수프

1. Beautiful Soup란?

- BeautifulSoup은 파이썬에서 사용할 수 있는 웹데이터 크롤링 라이브러리이다.

2. 사용방법

- bs4 라는 라이브러리 내에서 BeautifulSoup 모듈을 가져온다.

```
from bs4 import BeautifulSoup
import requests

url = "크롤링하려는 웹페이지의 주소"
response = requests.get(url)

soup = BeautifulSoup(response.content,"html.parser")
```

- `requests` 모듈은 http페이지에게 요청을 보내고, 그 요청의 결과를 받아올 수 있는 함수를 가진 모듈임.
- `requests.get(url)` 은 url에 담겨있는 http페이지 주소를 요청하여(주소로 이동하는 것과 같음) 그 주소의 요소들을 가져올 수 있도록 연결함.
- response라는 변수에 연결의 결과를 담고 `response.content`, 요청으로 받아온 결과의 내용을 `html.parser` 라는 html해석기로 내용을 html tag 구조로 해석함.

```
# 실행 코드
print(soup.prettify())
```

- `prettify()` 함수를 사용하면 정돈 되어있지않은 html구조가 반환되지만, `print()` 함수를 사용하여 그 결과를 출력해주면 위 사진과 같은 모습으로 들여쓰기까지 되어 보기좋게 출력됨.
- 모든 태그들의 내용은 soup 에 담겨있으며 그 중에서 태그명, id, class를 사용하여 검색해서 데이터를 추출하는 방식이 뷰티풀수프의 주된 크롤링 방법.

- 다만 뷰티플수프의 큰 한계점은 동적인 페이지의 크롤링이 불가하다는 것이다. 버튼을 누르거나 값을 입력하거나 하는 등의 페이자와의 동적인 상호작용이 불가능하다는 것.
- 하지만 웹 페이지의 모든 정보를 이미 soup에 전부 가져온 뒤 추출한다는 점에서 셀레니움보다 훨씬 빠르다는 장점을 가지고 있음.

2. 함수 이용

find

- find 함수는 HTML의 내용을 위에서부터 읽어내려오면서 h4라는 태그를 발견하면 그 값을 반환하고 종료하는 방식.

```
# 원하는 부분의 HTML 태그 및 CSS를 알아내어 find 함수로 값을 가져옴
soup.find("h4")
```

```
<!-- 실행결과 -->
<h4>2021 백엔드 개발자 로드맵</h4>
```

- find 함수는 HTML의 내용을 위에서부터 내려오면서 h4 라는 태그를 발견하면 그 값을 반환하고 종료하는 방식임.
- 다만 원하는 부분을 추출한다거나 여러 값을 추출하는데 부적절하여 `find_all()` 함수를 사용함

find_all

```
soup.find_all("h4")
```

```
<h4>2021 백엔드 개발자 로드맵</h4>,
 <h4>브라우저 렌더링 과정과 최적화</h4>,
 .....(생략)
 <h4>도커 컴포즈를 이용한 Express-Typescript-MySQL 개발환경 구축</h4>,
 <h4>브라우저 최적화</h4>,
 <h4>있어보이는 README 작성법</h4>,
 <h4>15. Deep Generative Models for Graphs</h4>
```

- find_all() 을 사용시 결과처럼 페이지 내 모든 h4 태그를 전부 가져온다.

select

```
len(soup.select("#root > div.sc-Rmtcm.gwGgYM > div.sc-fjdhpX.rMlhG > div.sc-bRBYWo.cdeiCz > main > div > div > div.sc-eqIVtm.jhiJFI > div > span"))
# 실행결과 3

len(soup.select("span"))
# 실행결과 96
```

- select 함수는 select()와 select_one() 함수가 있는데, find와 반대로 기본형은 select가 해당하는 모든 요소를 추출하는 함수임.
  CSS요소 상속, class, id 등을 사용하여 선택이 가능하여 효율적인 사용 가능.

위의 함수를 사용하여 요소를 추출하고, 이러한 과정을 for, 함수화 하여 많은 데이터를 추출하여 pandas를 사용해 DataFrame으로 만드는 과정까지가 크롤링의 주 목적